医療ガイドラインにおけるRAG手法の比較検証：因果推論アプローチによるチャンク戦略の再考

1. Executive Summary（概要）

- **目的**: 医療領域（食物アレルギー診療ガイドライン）に特化したQAシステムにおいて、検索精度と回答品質を向上させる最適なチャンク戦略を特定する。
- **検証手法**: 標準的な「ベースラインRAG」と、文脈を保持して検索する「Advanced RAG（Sentence Window Retrieval）」の2手法を比較。因果推論アプローチ（対応のあるt検定およびサブグループ解析）を用いて平均処置効果（ATE）を測定した。
- **結論**: Advanced RAGの導入による「忠実性（Faithfulness）」および「正確性（Answer Correctness）」の統計的に有意な改善は確認されなかった（むしろスコアが微減する傾向が見られた）。医療ガイドライン特有の「情報の密集度」や「文脈の連続性」において、単純な文単位の分割が裏目に出た可能性が示唆された。

2. Background（背景と課題）

- **背景**: 医療現場でのLLM活用において、事実と異なる情報を生成する「ハルシネーション」の排除は、患者の安全に関わる重大な課題として指摘されている[1]。近年、事実に基づく回答を可能にするRAG（検索拡張生成）の導入が進んでいるが、医療ガイドラインのような専門的かつ複雑な構造を持つ長文ドキュメントにおいては、「検索ノイズ」や「文脈の喪失」が発生しやすいという技術的課題が残っている。本検証ではこの課題に対し、チャンク戦略の観点から最適なアプローチを模索する。
- **課題（仮説）**: 従来の大きなチャンク（512トークンなど）で分割する手法では、質問に無関係な情報が混入し、LLMの推論を妨げるノイズとなる。
- **解決策**: 検索時は「1文」単位で正確にヒットさせ、回答生成時には「その前後数文」を文脈として付与するAdvanced RAG（Sentence Window Retrieval）を導入することで、回答の忠実性と正確性が向上するはずである、という仮説を立てた。

Generated by Notion to PDF

3. Methodology（実験設計と評価手法）

3.1. データセット

- 日本小児アレルギー学会が一般公開している『食物アレルギーの診療の手引き2023』（PDF）をダウンロードし、データセットとして使用し、gemini 3.1 pro により作成させた30問のQAデータ。

3.2. 介入の定義（比較システム）

- **Control群：**
  ベースラインRAG。標準的な `SentenceSplitter` を使用（Chunk size: 512, Overlap: 50）。
- **Treatment群：**
  Advanced RAG。日本語の句点や改行を考慮したカスタムパーサーと `SentenceWindowNodeParser` を使用し、文単位で検索しつつ前後の文（Window size: 2 ※コード上の設定値）を付与する手法。

【補足】平均処置効果（ATE）算出における因果推論の前提条件の確認
本検証においてATEを妥当に推定するため、以下の因果推論の基本仮定が満たされていることを確認した上で実験を設計している。

1. **SUTVA（相互干渉の不在）**: 本システムはチャット履歴を保持しないステートレスなAPI呼び出し（1問1答形式）で実装している。したがって、「ある質問（Unit）に対する回答生成が、他の質問の回答精度に影響を与える（Leakage）」ことはなく、相互干渉は存在しない。
2. **Consistency（介入の明確な定義）**: Treatment群の介入は「Sentence Window Retrieval（Chunk=1文, Window=前後2文）」というパラメータ設定としてシステム上に一意に定義されており、確率的なブレのない明確な介入（Well-defined intervention）となっている。
3. **Unconfoundedness（交絡の不在）**: 同一の30問に対し、Control群とTreatment群の両システムで並行して推論を実行する対応のある設計としているため、質問の難易度や性質による交絡は排除されている。

3.3. 評価指標（Metric）

LLMの回答品質を定量的に測定するため、LLM-as-a-Judge（LLMによる自動評価）フレームワークである「Ragas」を採用した[2]。本検証では、特にハルシネーションの抑制と回答の的確さを測るため、以下の2指標に絞って平均処置効果（ATE）を測定した。

- **Faithfulness（忠実性）**: 検索したコンテキスト（参照資料）からの逸脱がないか。

Generated by Notion to PDF

- **Answer Correctness（正確性）**: 模範解答（Ground Truth）と生成された回答の意味的合致度。

4. Overall Results（全体評価：平均処置効果の検証）

- **忠実性（Faithfulness）の結果**:
  - Control平均: 0.858 / Treatment平均: 0.773
  - ATE（平均処置効果）: -0.086 ポイント
  - 検定結果: p値 = 0.3725（p >= 0.05 により有意差なし）
- **正確性（Answer Correctness）の結果**:
  - Control平均: 0.247 / Treatment平均: 0.210
  - ATE（平均処置効果）: -0.037 ポイント
  - 検定結果: p値 = 0.1559（p >= 0.05 により有意差なし）

全体解釈: Advanced RAG（Treatment）の導入は、全体としてスコアを押し下げる結果となった。医療文書においては、512トークンという「ある程度の情報のまとまり」を与えた方がLLMが適切に回答を生成できることがわかった。

5. Deep Dive（サブグループ解析と異質的処置効果）

5.1. 質問意図による分類（Factoid vs Reasoning）

- **Reasoning（論理展開型 / n=10）**: 「なぜ」「理由」「違い」など、複数要素の理解や推論を求める質問。
- **Factoid（事実検索型 / n=20）**: 特定の用語、数値、手順などをピンポイントで問う質問。

5.2. サブグループ別の検定結果と効果量（Cohen's d）

- **Reasoning群**: 忠実性（ATE=-0.100, p=0.591）、正確性（ATE=-0.0002, p=0.872）。論理展開型では両システムで差がほぼ出なかった。
- **Factoid群**: 忠実性（ATE=-0.078, p=0.496）、正確性（ATE=-0.055, p=0.158）。事実検索型の方がスコア低下の振れ幅がやや大きかった。

ReasoningとFactoid群のバイオリンプロットとスロープグラフ

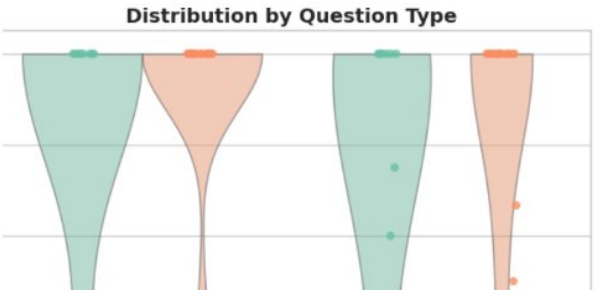

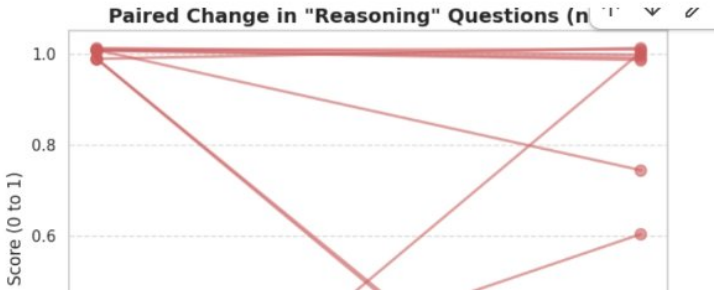

Generated by Notion to PDF

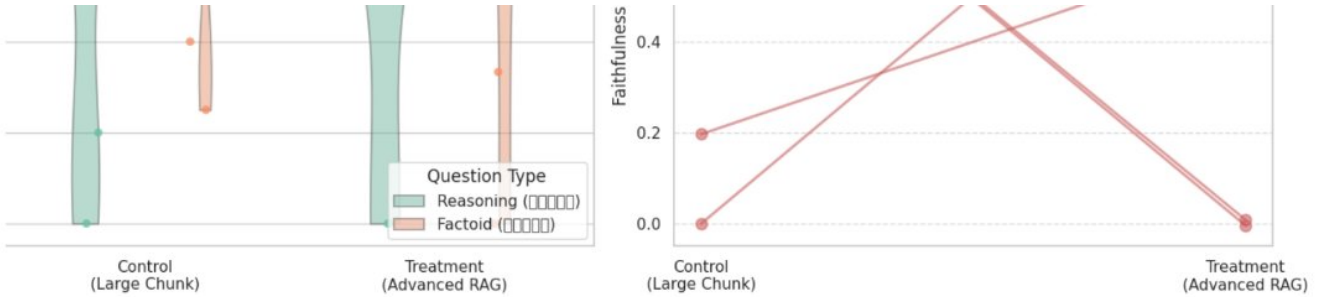

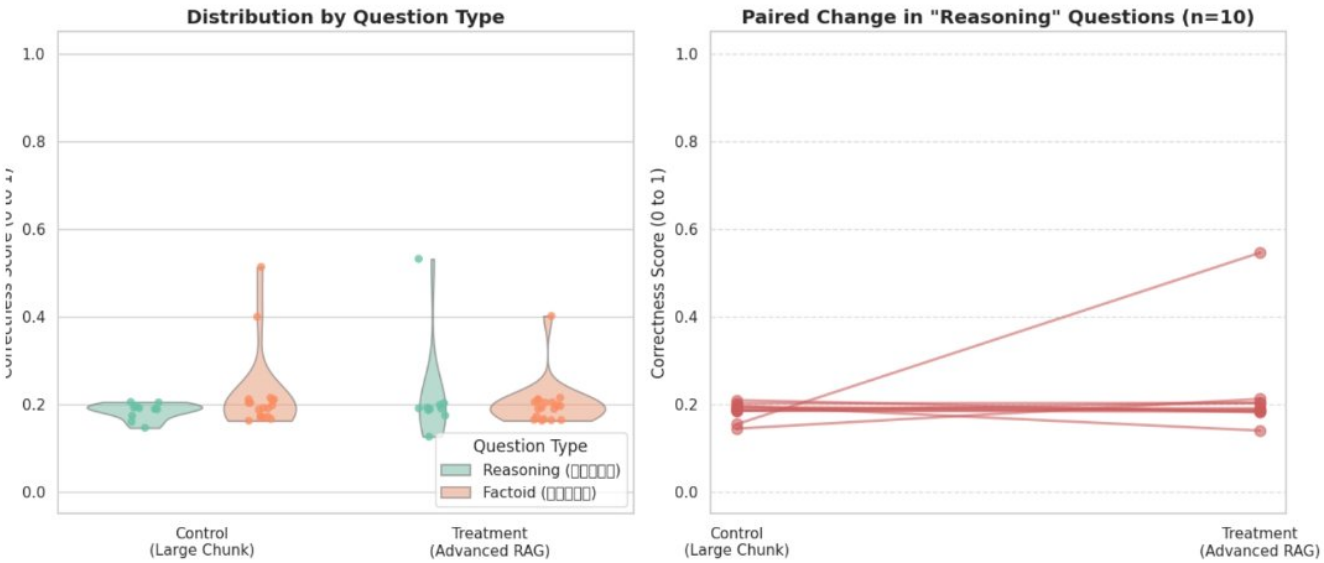

忠実性スコアは高い所に密集しており更にスロープグラフも比較的に高いところでまとまっている。しかし、正確性スコアは両者共に0.2付近と低いところで密集している。スロープグラフをみてもあまり改善が見られない

6. Discussion（考察）

6.1. チャンク戦略の適性（なぜSentence Windowは優位性を示せなかったのか）

本検証の統計的検定が示す通り、両手法間に有意なスコア差は確認されなかった。しかし、「Sentence Windowを導入することでノイズが減り、精度が向上する」という事前仮説は棄却され、むしろ平均値としては微減する傾向（Control同等以下の精度）にとどまった。この要因として以下の2点が推察される。

- **医療文書の構造とSentence Windowの不一致**: この文書は、「箇条書き」「表の注釈」「略語や用語の解説」など、複数文にまたがって初めて意味を成す構造が多用される。文単位で分割して前後2文だけを付与するTreatment群の手法では、箇条書きの親項目（前提条件）が欠落するなど、結果的にLLMに渡される文脈が不完全になってしまったケースがあったと考えられる。
- **Large Chunkに対する最新LLMの堅牢性**: 一方でControl群の大規模チャンク（512トークン）は、文書のまとまりをある程度保持している。Gemini 2.5 Flashのような最新LLMの高度な情報抽出・読解能力をもってすれば、512トークン程度のコンテキスト内に多少のノイズが含まれていても、自力で必要な情報を適切に取捨選択できる。そのため、無理に検索側で文を絞り込むアプローチが「スコアを押し上げるほどの優位な差」を生み出せなかったと言える。

Generated by Notion to PDF

6.2. 正確性（Answer Correctness）の全体的な低スコアに関する考察

本実験において、Answer CorrectnessのスコアはControl群（0.247）、Treatment群（0.210）ともに絶対値として低水準にとどまった。この原因として以下の3点が推察される。

- **評価指標とGround Truth（模範解答）のミスマッチ**: RagasのAnswer Correctnessは、生成された回答と模範解答の意味的な合致度や事実の網羅性を評価する。Ground Truthが「簡潔な単語や一文」で定義されているのに対し、LLMが「補足説明を含む冗長な回答」を生成した場合、ペナルティを受けてスコアが低下しやすい。
- **医療ドメインの複雑性**: 専門用語や複雑な条件分岐を含む質問に対し、システムが「部分的には正しいが、ガイドラインが求める厳密なニュアンスや条件を完全には満たしていない」回答を生成している可能性が高い。
- **評価モデル（LLM-as-a-Judge）の限界**: 採点を行うLLM自身が、高度な医学的推論を完全に評価しきれず、厳格すぎる（あるいは文脈を読み違えた）採点を行っているリスクも考慮すべきである。

6.3. データ分布の偏りと統計手法に関する限界

本検証では平均処置効果（ATE）の測定に対応のあるt検定を用いたが、バイオリンプロットによるデータの可視化において、**スコアの分布が正規分布（t分布）に従っていない**ことが確認された。

- **分布の偏り（極端なスコア化）**: LLMによる自動評価（Ragas）の特性上、スコアが中間の連続値にならず、「0（不正解）か1（正解）」あるいは特定の点数帯に偏る双峰性（バイモーダル）や裾の重い分布になっている。
- **統計的解釈への影響と今後の課題**: t検定はデータが正規分布に従うことを前提（パラメトリック）としているため、今回のp値は参考値として捉える必要がある。正確な効果測定のためには、外れ値や非正規分布に強い非パラメトリック検定の適用や、平均値ではなく「中央値」を用いた評価への切り替えを今後の課題としたい。

6.4. 効果量（Cohen's d）の微小性が示唆するビジネス的意義

本検証において算出された効果量（Cohen's d）は、忠実性・正確性ともに極めて小さい値（またはマイナス）にとどまった。この「効果量が微小である」という結果は、実装が複雑で推論時のチャンク処理コストも増加する「Sentence Window Retrieval」を無理に導入しても、得られる回答精度の向上（リターン）はほぼゼロに等しいということである。現段階の医療ガイドラインQAにおいては、運用・保守コストの観点からも、構造がシンプルでLLMの素の読解力を活かせる「ベースラインRAG（大チャンク）」を採用する方が、費用対効果（ROI）の高いアーキテクチャであると結論づけられる。

7. Limitations & Future Architecture（限界と次期システム構想）

Generated by Notion to PDF

7.1. 本検証の限界（Limitation）

- サンプルサイズがN=30問と小さく、統計的な検出力が不足していた可能性。
- 『食物アレルギーの診療の手引き』という単一のドキュメント形式での検証であり、表形式データ（PDFからテキスト化する際の構造崩れ）に対する前処理の限界が含まれている。

7.2. 本番システムへの実装構想

- **Semantic Chunking / Document Structure Parsing**: 単純な文字数や「。」での分割ではなく、Markdown変換や見出し単位・段落単位での構造的チャンキング（LlamaParse等の導入）を採用する。
- **Hybrid Retrievalの導入**: ベクトル検索だけでなく、医療用語の欠落を防ぐためのキーワード検索（BM25など）を併用する。
- **Agentic RAGへの進化**: 事前にユーザーの質問意図（FactoidかReasoningか）を分類し、Factoidなら細かなチャンク、Reasoningなら広範なセクションを取得するといった動的ルーティングを実装する。

Appendix: 開発・実装プロセスについて

本検証のPython実装（Ragasによる評価パイプライン構築等）にあたっては、開発生産性の向上のため生成AI（gemini3.1pro）を活用してコーディングを行っている。ただし、プロンプトエンジニアリングによるアーキテクチャ設計、生成されたコードのロジック検証、および統計的検定の妥当性確認は、全て人間（筆者）による厳密なレビューと修正を経て実行している。

8.参考文献

1] 順天堂大学. "放射線科医の診療コンサルト業務をAIが支援する実証実験を開始 〜ハルシネーション（もっともらしいウソ）のないセキュアな生成AI環境を構築〜". https://www.juntendo.ac.jp/news/23442.html (参照: 2026年3月10日)

[2] umi_mori. "RagasによるRAGの精度評価（LangChain × Python）". Zenn. https://zenn.dev/umi_mori/books/llm-rag-langchain-python/viewer/rag-accuracy-ragas (参照: 2026年3月10日)

Generated by Notion to PDF